

Домашнее задание 7


Построение и анализ филогенетических деревьев

Кирилл Афанасьев, гр. Б06-305

Задание 1: Подготовка данных

Для выполнения данного задания используем ген β -актина человека (ACTB), NP_001092.1. Выбор пал на него из-за консервативности последовательности, что делает его удобным объектом для филогенетического анализа.

Ортологи были получены при помощи соответствующей вкладки в базе данных NCBI (<https://www.ncbi.nlm.nih.gov/datasets/gene/60/?taxon=8782#orthologs>). Изначально было предложено 730 ортологов, однако для уменьшения времени расчета деревьев было принято ограничиться одной кладой - Птицы (Aves). Данный таксономический фильтр позволил ограничить число ортологов до 160.



Scientific name	Symbol	Chromosome	Isoforms	Protein accession	Length (aa)	Architecture	Action
☒ Gallus gallus (chicken)	ACTB	14	1	NP_990849.1	375		
☒ Taeniopygia guttata (zebra finch)	ACTB	14	1	XP_030140438.1	375		
☒ Sylvia atricapilla (blackcap)	ACTB	15	1	XP_066185886.1	375		
☒ Anas platyrhynchos (mallard)	ACTB	15	1	NP_001297350.1	375		
☒ Columba livia (rock pigeon)	ACTB	15	1	XP_064887486.1	375		
☒ Zonotrichia albicollis (white-throated sp...)	ACTB	16	1	XP_005487470.1	375		
☒ Haemorrhous mexicanus (house finch)	ACTB	17	1	XP_059717202.1	375		

Рис. 1: Часть ортологов ACTB у птиц.

Теперь, в полученном файле **protein.faa**, переименуем строки заголовков согласно заданию. Для этого используем команду в терминале:

```
kirill@AKA-30062023: ~/homework7
(base) kirill@AKA-30062023:~/homework7$ cd homework7
(base) kirill@AKA-30062023:~/homework7$ sed -E 's/>([A-Z0-9_]+).*\[organism=([A-Za-z ]+)\].*/>2_1/; s/ /_/g' protein.faa > renamed_protein.faa
(base) kirill@AKA-30062023:~/homework7$ head -5 renamed_protein.faa
>Gallus_gallus_NP_990849.1
MDDIIAALVVDNMSGMCKAGFAGDDAPRAVFPISIVGRPRHOGVMVGMDKDSYVGDEAOSKRGILTLPKYP
IEHGIVTNWDDMEKIWHHTFYNELRVAPPEHPVLLTEAPLNPKANREKMTQIMFETFTNPAMYVAIQAVL
SLYASGRITGIVMDSGDGVTHTVPIYEGYALPHAILRLDLAGRDLDYLMKILTERGYSFTTTAEREIVR
DIKEKLCYVALDFEQEMATAASSSSLEKSYELPDGQVITIGNERFRCPALFQPSFLGMESCGIHETTFN
(base) kirill@AKA-30062023:~/homework7$
```

Рис. 2: Команда, меняющая строки заголовков.

Задание 2: Множественное выравнивание

Выравнивание 160 последовательностей провели сразу локально в программе **MEGA** при помощи алгоритма **MUSCLE** с параметрами по умолчанию. Данный выбор был обусловлен тем, что **MUSCLE** лучше подходит для выравнивания консервативных белковых последовательностей, а наш АСТВ консервативен, т.к. менее склонен к созданию артефактов и лучше работает с большими объемами данных.




Рис. 3: Результаты выравнивания.

В результате выравнивания можем заметить наличие как консервативных участков, точечных аминокислотных мутаций, так и переменных участков.

Задание 3: Построение филогенетических деревьев

3.1

Для выбора лучшей модели молекулярной эволюции (Best Fit Substitution Model) используем функцию Find Best DNA/Protein Models:




Рис. 4: Результаты анализа моделей молекулярной эволюции.

По критерию BIC лучшей моделью является WAG+I, с BIC = 7252.237.

3.2

Теперь для найденной лучшей модели, в нашем случае **WAG+I**, построим **ML** (Maximum Likelihood) **дерево** с параметром **bootstrap = 100**. Полученное дерево приведено на Рис. 5 и 6 ниже:



Рис. 5: Часть 1




Рис. 6: Часть 2

3.3

Построим NJ (Neighbor-Joining) дерево с параметром **bootstrap = 100**, используем модель **p-distance**.
Полученное дерево приведено на Рис. 7 и 8 ниже:




Рис. 7: Часть 1




Рис. 8: Часть 2

Построим **UPGMA** **дерево** с параметром **bootstrap** = 100. Полученное дерево приведено на Рис. 9 и 10 ниже:

Рис. 10: Часть 2

Зам. Полные изображения деревьев в формате .png приложены в папке `homework7` вместе с отчетом.

Задание 4: Анализ и сравнение результатов

4.1

Сравним полученный деревья по показателям `bootstrap`.

Наибольшую статистическую поддержку узлов демонстрирует ML дерево. Например, одним из ключевых узлов дерева, является узел, разделяющий виды голубей (*Nesoenas*, *Streptopelia*, *Caloenas*, *Patagioenas*), для него `bootstrap` = 62%. Также клада ибиса (*Nipponia*) и стрижа (*Chaetura*) имеет высокое значение `bootstrap` = 97%. Ну и внутренние узлы внутри клады Воробьинообразных (*Passeriformes*) имеют значения от 66 до 99 %. Однако, большинство узлов всё же имеют не настолько большие значения.

NJ дерево показывает более низкую поддержку по сравнению с ML: многие `bootstrap` значения находятся в диапазоне от 2 до 70%, больше всего значений близких к 60 %. Это указывает на меньшую надёжность.

UPGMA дерево имеет поддержку узлов в большом диапазоне значений `bootstrap` за счёт того, что оно часто завышает значения из-за предположения о постоянстве скорости эволюции, которое не выполняется для реальных данных.

Таким образом, ни одно дерево, в явном виде, не демонстрирует высокой поддержки каждого из узлов. Но ML дерево обладает наилучшей балансировкой между разрешающей способностью и статистической надёжностью, в связи с использованием наилучшей определённой модели - `WAG+I`. `bootstrap` поддержка NJ дерева ниже. UPGMA деревья сложно интерпретировать с точки зрения временной эволюции.

4.2

Если сравнить топологию полученных деревьев с известной таксономией птиц, то можно выделить следующие ключевые паттерны.

У ML дерева получилось выделить голубей ((*Nesoenas*, *Streptopelia*, *Caloenas*, *Patagioenas*) в монофилетическую группу, что соответствует современным представлениям о систематике. *Nipponia nippon* (ибис, отр. *Pelecaniformes*) и *Chaetura pelagica* (стриж, отр. *Apodiformes*) сгруппированы вместе с поддержкой 97% — это приемлемо, так как оба вида относятся к *Neoaves*, хотя и к разным отрядам. Объёмное ветвление внутри отр. Воробьинообразные (*Passeriformes*), в целом, также соответствует современным представлениям об эволюции птиц. Однако, некоторые глубокие узлы имеют поддержку ниже 50%, что всё же говорит нам о высокой консервативности АСТВ и его малой длине в 375 аминокислот.

NJ дерево также справилось с тем, чтобы объединить голубей в монофилетическую группу. Но многие остальные внутренние узлы имеют очень низкую поддержку, что делает топологию дерева ненадежной.

UPGMA дерево также справилось с группировкой голубей, причем с хорошей поддержкой в 68%. Однако, в силу предположения о постоянстве скорости эволюции, дерево склонно к объединению в монофилетические группы таксонов с длинными ветвями. Так страус (*Struthio camelus*) оказался внутри *Neoaves*, хотя по современным данным это базальная ветвь. Аналогично были объединены *Fulmarus glacialis* (буревестник) с *Coturnix japonica* (перепел), что биологически неверно — это разные надотряды (надотр. *Aequornithes* и надотр. *Galloanserae*).

таким образом, ML дерево наиболее биологично, так как его топология в основном соответствует современной таксономии птиц, несмотря на низкую поддержку некоторых узлов. Ошибки же можно связать с высокой консервативностью АСТВ.

4.3

Можно увеличить количество `bootstrap` реплик. Использовать около 500, а то и 1000. Это точно повысит надежность оценки поддержки узлов, но достаточно сильно увеличит время расчета.

Можно пересмотреть выравнивание вручную. Например можно удалить участки с большим числом пропусков, это позволит улучшить качество выравнивания. Ещё в анализе наблюдались довольно близкие последовательности (почти идентичные), которые могут сильно искажать **bootstrap** и увеличивать время расчетов. Их можно убрать.

Также можно взять ещё белки-маркеры для анализа, желательно менее консервативные. Это позволит улучшить разделение ветвей.