

Домашнее задание и семинар 1

Метагеномика

Кирилл Афанасьев, гр. Б06-3046

Семинарская часть

На семинаре мы рассматривали статью S. P. Rosshart et al., Cell 171, 1015 (2017), в которой лабораторным мышам пересаживалась микробиота диких мышей - WildR, либо лабораторных - LabR. Если рассмотрим обозначения, то W - дикие мыши, L - лабораторные мыши, LR - с пересаженной лабораторной микробиотой, WR - с пересаженной дикой микробиотой. Для определения таксономического состава микробиома секвенировали V4 участок гена 16S рРНК. Всего брали 29 образцов.

Качество сырых данных

Получили сводку через MultiQC:




Рис. 1: MultiQC: Mean Quality Scores.




Рис. 2: MultiQC: Per Sequence Quality Scores.

Как можно заметить плохих прочтений среди всех 58 файлов почти нет. Качество около 35 достигается вплоть до 150 позиции.

Импорт и статистика сырых прочтений

После загрузки данных в формате qza и получения статистики с сырых прочтений при помощи команд соответствующих команд из презентации, получили следующие результаты.




Рис. 3: Качество сырых прочтений (прямых и обратных).

Видим, что прямые прочтения держат верхний квартиль около 38, к 230 и после все начинает снижаться, начиная с 225 нижние усы опускаются вплоть до 2. Обратные прочтения начинают падать раньше, уже начиная с 165.

	forward reads	reverse reads
Minimum	2138	2138
Median	4918.0	4918.0
Mean	4643.862069	4643.862069
Maximum	6394	6394
Total	134672	134672

Рис. 4: Статистика по числу прочтений

В итоге видим на 29 образцов суммарно 134672 прочтения. В среднем 4644 прочтения.

DADA2

```
qiime dada2 denoise-paired \
  --i-demultiplexed-seqs qza/mice_reads.qza \
  --p-trim-left-f 19 \
  --p-trim-left-r 20 \
  --p-trunc-len-f 240 \
  --p-trunc-len-r 200 \
  --p-n-threads 16 \
  --o-table qza/mice_ASV_table.qza \
  --o-representative-sequences qza/mice_rep_seq.qza \
  --o-denoising-stats qza/mice_reads.dada2.stats.qza
```

-p-trim-left-f 19 - длина праймера 515F. -p-trim-left-r 20 - длина праймера 806R. -p-trunc-len-f 240 и -p-trunc-len-r 200 выбраны по границам резкого снижения качества ридов.

Прямое и обратное прочтение после фильтрации и обрезки покрывает 221 нуклеотид. Исходя из результатов обратное прочтение полностью укладывается внутри прямого с лабильностью относительно минимального перекрытия слияния в 12 нуклеотидов.

Фильтр качества проходит достаточно большой разброс: от 68.01% до 83.99%. Итоговый фильтр, нехимерность, проходит от 53.19% (W6) до 73.98% (LR5). Стоит отметить, что для диких мышей характерно меньшее сохранение после фильтрации, т.к. наблюдается большее число химер и иных редких вариантов.

sample-id seq2-types	input numeric	filtered numeric	percentage of input passed filter numeric	denoised numeric	merged numeric	percentage of input merged numeric	non-chimeric numeric	percentage of input non-chimeric numeric
L1	3773	2821	74.77	2670	2533	67.13	2515	66.66
L2	3669	2744	74.79	2585	2374	64.7	2374	64.7
L3	5346	4087	76.45	3881	3517	65.79	3340	62.48
L4	3836	2733	71.25	2579	2264	59.02	2264	59.02
L5	3311	2356	71.16	2202	2007	60.62	1973	59.59
L6	4572	3298	72.13	3157	2902	63.47	2862	62.6
L7	4536	3311	72.99	3132	2894	63.8	2894	63.8
L8	3498	2445	69.9	2308	2147	61.38	2147	61.38
LR1	5047	4239	83.99	4076	3754	74.38	3754	74.38
LR2	6394	5281	82.59	5122	4681	73.21	4681	73.21
LR3	5753	4631	80.5	4459	4026	69.98	4026	69.98
LR4	6062	4864	80.24	4700	4397	72.53	4371	72.1
LR5	6056	4888	80.71	4740	4480	73.98	4480	73.98
LR6	5855	4658	79.56	4528	4092	69.89	4092	69.89
LR7	5191	4253	81.93	4082	3789	72.99	3789	72.99
W1	2138	1521	71.14	1415	1294	60.52	1257	58.79
W2	3714	2526	68.01	2359	2191	58.99	2127	57.27
W3	3211	2539	79.07	2398	2235	69.6	2115	65.87
W4	3619	2666	73.67	2492	2224	61.45	2185	60.38
W5	4301	3086	71.75	2871	2560	59.52	2477	57.59
W6	5016	3270	65.19	3047	2715	54.13	2668	53.19
W7	3501	2436	69.58	2298	2198	62.78	2062	58.9
WR1	4804	3826	79.64	3646	3399	70.75	3399	70.75
WR2	4918	3792	77.1	3600	3386	68.85	3386	68.85
WR3	5446	4329	79.49	4138	3664	67.28	3625	66.56
WR4	5206	4078	78.33	3837	3474	66.73	3474	66.73
WR5	5450	4148	76.11	3971	3589	65.85	3589	65.85
WR6	5414	4274	78.94	4095	3672	67.82	3640	67.23
WR7	5035	4086	81.15	3908	3632	72.14	3632	72.14

Рис. 5: Сводная таблица по статистике фильтрации.

Таблица ASV

Ниже рассмотрим результаты в виде таблицы ASV.

Table summary

Summary Statistic	Value
Number of samples	29
Number of features	517
Total frequency	89,198

Рис. 6: Сводка ASV.

Как можно заметить, на 29 образцов мы имеем 517 ASV и 89198 прочтений. Минимальная глубина - 1257, у W1. Максимальная глубина - 4681, у LR2. Медиана на 3340. Медиана частоты ASV - 45, наблюдается при минимальном значении 2, максимальном - 4761 и среднем - 172.5. Распределение частот ASV сильно скошено влево, как можно заметить, заметен хвост из редких вариантов.

Таксономия

```
qiime feature-classifier classify-sklearn \
  --i-classifier 2022.10.backbone.v4.nb.sklearn-1.4.2.qza \
  --i-reads qza/mice_rep_seq.qza \
  --o-classification qza/mice_taxonomy.qza \
```




Рис. 7: Распр-е частот по образцам.




Рис. 8: Распр-е частот по ASV.

--p-n-jobs 16

Выше приведен использованный классификатор таксономии, это наивный байесовский классификатор. Для каждого ASV он выдает самый глубокий уровень таксономии с уверенностью не меньше 0.7 - параметр по умолчанию.

Определим таксономический состав сообщества через построение qiime taxa barplot, при помощи соответствующих команд из презентации, по таблице ASV.




Рис. 9: Taxa barplot на Level 2.

На уровне 3, постдоменная структура, заметна разница в составе сообществ микрофлоры у разных мышей. У дикого типа и лабораторных мышей с пересаживаемой от дикого типа микрофлорой большее разнообразие первичных бактериальных клад. Причем структура похожа, однако у WR начинает преобладать Firmicutes, что похоже на лабораторных мышей. Как раз у лабораторных мышей более скудное разнообразие, среди которого явно преобладает постдомен Firmicutes.

На уровне 6, это уже уровень родов, видим большую мозаичность таксономического разнообразия у дикого типа, хотя сохраняются некоторые преобладающие представители. У лабораторных мышей мозаичность менее выражена.

Наблюдения согласуются с данными статьи.




Рис. 10: Taxa barplot на Level 6.

Филогенетическое дерево

Команда из семинара у меня не сработала, поэтому построил дерево через <https://itol.embl.de/>, получилось следующее дерево:



Рис. 11: Филогенетическое дерево 516 ASV.

Альфа-разнообразие (индекс Шеннона)

Как видно из Рис. 12, наименьшее разнообразие достигается в группе W, после нее идет L, наибольшие разнообразия характерны для LR.

Рассмотрим результаты теста Краскала-Уоллиса. По всем группам - $H = 18.22$, $p\text{-value} = 3.9 \cdot 10^{-4}$.

Исходя из резюмирующей таблицы теста (Рис. 13) видим, что значительно различаются все пары, кроме LR и WR. Опять же, видим, что разнообразие у дикого типа больше чем у лабораторного. У LR и WR разнообразие выше, чем у исходных доноров. Таким образом, альфа-разнообразие показывает факт колонизации лабораторного штамма, но не показывает источник.




Рис. 12: Индекс Шеннона по группам.

Kruskal-Wallis (pairwise)

[Download CSV](#)

Group 1	Group 2	H	p-value	q-value
L (n=7)	LR (n=7)	9.016327	0.002676	0.008099
	W (n=6)	5.807959	0.015158	0.021704
	WR (n=7)	5.587755	0.018086	0.021704
LR (n=7)	W (n=6)	9.000000	0.002700	0.008099
	WR (n=7)	0.036735	0.848006	0.848006
W (n=6)	WR (n=7)	8.163265	0.004275	0.008549

Рис. 13: Результаты теста Краскела-Уоллиса.

Бета-разнообразие




Рис. 14: PCoA weighted UniFrac.





Рис. 15: PCoA unweighted UniFrac.

Результаты Weighted UniFrac. L и LR образуют отдельный небольшой кластер, дикий тип довольно сильно отдален от данного кластера. Причем разброс дикого типа больше, чем у лабораторных. Это подтверждает то, что дикий микробиом сильно вариабельнее.

Результаты Unweighted UniFrac. Дикие и лабораторные группы всё также разделены вдоль оси абсцисс. Причем лабораторные группы, L и LR, частично перекрываются. В отличие от диких.

Permanova



Видим значимость всех попарных сравнений. Наименьшее различие между L и LR, больше всего различий между L и WR. Интересно, что пара W и WR различается сильнее, чем пара L и LR. Это говорит о том, что лабораторная микробиота в новом хозяине воспроизводится лучше, чем дикая.

Выводы

Исходя из таксономических барплов, видим, что лабораторная микробиота однообразна. Дикая микробиота наоборот гетерогенна.

Исходя из результатов по альфа-разнообразию, у LR и WR оно выше, чем у обоих доноров. У W разнообразие меньше, чем у L.

Исходя из результатов по бета-разнообразию, разброс диких групп значительно больше лабораторных, лабораторные группы образуют кластер. Статистика Перманова подтверждает различия во всех парах групп.

Полученные результаты частично согласуются с данными статьи. Понятно, что микробиота дикого типа и лабораторных мышей различаются по таксономическому составу и структуре.

Стоит отметить, что мы везде использовали ASV. В статье же использованы OTU. При этом авторы сами перепроверили данные алгоритмом subOTU, который лежит в основе DADA2, и получили, что основные выводы OTU-анализа подтверждаются. Так что наш подход методически ближе к их дополнительному анализу.

Домашняя часть (почвенный микробиом)

В данной части рассматривались результаты секвенирования региона V4-V5 16S рРНК изъятых из образцов почвы разной степени обработки загрязняющими агентами (керосином). Среди образцов представлены следующие: $k0$ - контроль, $k5$ - 5 г керосина на кг почвы, $k25$ - 25 г керосина на кг почвы. При этом образцы изымались в разные моменты времени: $t1$ - день 3, $t2$ - день 90, $t3$ - день 180, $t4$ - день 360. Каждая экспериментальная точка баралсь в трех повторностях. Тогда, итого, получаем суммарно 36 образцов.

Задача 1

Провели FastQC на одном из файлов образцов, был выбран: SRR17307316_1.fastq

Исходя из базовой статистики, видим, что в образце 10833 прочтения. Длина последовательности 251 нуклеотид, обогащена GC на 57%. Некачественных прочтений нет.




Рис. 16: Per base sequence quality.




Рис. 17: Per sequence quality scores.

Медиана остается в зелёной трети по всей длине прочтения. Падает вниз лишь хвост распределения. Рассмотрим сводку: 9-й перцентиль падает с 37 (около примерно 50 позиции) до 20 на 250 позиции.

задача 2

Первые 25 нуклеотидов прочтения являются праймером 515F и его линкером. Данная часть прочтения не из бактериального генома. Без его удаления DADA2 принял бы нуклеотиды праймера за биологический сигнал и разделил бы один организм на разные ASV.

Также первые первые циклы работы секвенатора дают ненадежные оценки качества этой части последовательности. Это также видно на Рис. 18:




Рис. 18: Per base sequence content.

Импорт и качество




Рис. 19: Качество прямых прочтений по всем образцам.

Demultiplexed sequence counts summary

	forward reads
Minimum	5128
Median	15852.0
Mean	17815.611111
Maximum	45492
Total	641362

Рис. 20: Сводная таблица по всем образцам.

Как можно заметить, всего 641362 прочтения на 36 образцов. Min - 5128, Median - 15852, Max - 45492. Разброс получается около девяти раз, получается, что дальше понадобится разрежение, т.к. это много.

DADA2

Используем команду со следующими параметрами:

```
qiime dada2 denoise-single \
  --i-demultiplexed-seqs qza/soil_reads.qza \
  --p-trim-left 25 \
  --p-trunc-len 200 \
  --p-max-ee 3 \
  --p-n-threads 20 \
  --p-pooling-method "pseudo" \
  --p-chimera-method "consensus" \
  --p-min-fold-parent-over-abundance 4 \
  --o-table qza/soil_ASV_table.qza \
  --o-representative-sequences qza/soil_rep_seq.qza \
  --o-denoising-stats qza/soil_reads.dada2.stats.qza
```

sample ID	reads	denoised	percentage of input passed filter	denoised	non-chimeras	percentage of input non-chimeras
SRR17307380	89991	89991	99.19	89420	89991	99.59
SRR17307380	1000	1000	99.93	9794	9794	99.59
SRR17307380	15047	15033	99.97	9893	9893	99.92
SRR17307380	24491	24490	99.9	24933	24994	99.9
SRR17307380	28034	28034	99.79	28030	28037	99.96
SRR17307380	10033	10030	99.98	10193	10099	99.96
SRR17307380	9801	9805	99.95	9873	9873	99.95
SRR17307380	9193	9197	99.9	9199	9199	99.79
SRR17307380	25034	25035	99.9	24977	24977	99.93
SRR17307380	9514	9501	99.9	9427	9477	99.42
SRR17307380	9814	9801	99.97	9799	9791	99.71
SRR17307380	12493	12493	99.92	12987	12989	99.99
SRR17307380	29493	29493	99.93	29879	29899	99.96
SRR17307380	1913	1910	99.93	1909	1909	99.93
SRR17307380	24934	24934	99.71	24993	24994	99.96
SRR17307380	9993	9991	99.91	9993	9991	99.97
SRR17307380	9471	9469	99.94	9479	9469	99.96
SRR17307380	45492	45497	99.91	44930	44919	99.96
SRR17307380	12791	12791	99.79	12993	12999	99.96
SRR17307380	91993	91993	99.77	91914	91999	99.94
SRR17307380	7914	7909	99.95	7909	7909	99.93
SRR17307380	91913	91913	99.9	91923	91926	99.99
SRR17307380	29197	29199	99.99	29199	29199	99.97
SRR17307380	9247	9249	99.99	9249	9249	99.94
SRR17307380	9499	9471	99.99	9479	9493	99.96
SRR17307380	19077	19099	99.95	19093	19099	99.79
SRR17307380	1009	1009	99.99	9997	9997	99.99
SRR17307380	27496	27499	99.79	28099	28099	99.72
SRR17307380	10047	10019	99.42	10197	10197	99.93
SRR17307380	29997	29997	99.95	29973	29973	99.71
SRR17307380	29993	29993	99.9	29799	29999	99.99
SRR17307380	6999	6972	99.97	6942	6954	99.99
SRR17307380	9393	9374	99.99	9371	9369	99.99
SRR17307380	14977	14979	99.99	14984	14989	99.99
SRR17307380	9977	9993	99.92	9791	9794	99.77
SRR17307380	39493	39479	99.79	39499	39499	99.77

Рис. 21: Статистика фильтрации DADA2.

Задача 3

Для ответа на данный вопрос заглянем в файл `soil_reads.dada2.stats.qzv`.

Получаем, что доля выживших прочтений в среднем около 94.9%. Колеблется от 89.3% до 97.1% от образца к образцу.

Самым большим образцом является SRR17307475 - 43518 прочтений после фильтрации.

Самым маленьким является SRR17307380 - 4809 прочтений.

О качестве данных это говорит то, что данные достаточно хорошего качества, т.к. фильтр отбирает по нему немного данных, больше уходит на денойзинг и поиск химер.

Таблица ASV

Использовалась команда:

```
qiime feature-table summarize \
  --i-table qza/soil_ASV_table.qza \
  --o-visualization qzv/soil_ASV_table.qzv \
  --m-sample-metadata-file soil_metadata_full.tsv
```

Представим результаты ниже:

Видим скошенное распределение из-за наличия доминантов и хвоста из редких вариантов.

Table summary

Summary Statistic	Value
Number of samples	36
Number of features	1,944
Total frequency	608,362

Рис. 22: Итог по таблице ASV.




Рис. 23: Распределение частот по образцам.




Рис. 24: Распределение частот по ASV.

Задача 4

Праймеры подбирали под участок V4-V5, однако работаем мы только с прямым прочтением. Начинается оно с праймера 515F, после обрезки покрывает примерно позиции 540-715. Т.е. оно полностью лежит внутри V4. До V5 просто не доходит. Поэтому V5 мы и не анализируем, его просто нет в наших данных.

Задача 5




Рис. 25: Состав на уровне класса (lv 3).

Теперь определим таксономический состав сообщества почвы. Для этого построим барплоты на разных уровнях.

В первой временной точке, на 3 день, образцы похожи. Медианные доли крайне близки по трем основным классам: Gammaproteobacteria, Acidobacteriae и Alphaproteobacteria.

Со временем состав меняется разнообразно в зависимости от дозы керосина. Контроль k0 меняется спокойно. Слабое загрязнение k5 максимально близко к контролю. А вот для сильного загрязнения, k25, картина совершенно отличается.

Теперь рассмотрим самые частые классы. В первой временной точке у всех трёх доз одинаково преобладают Acidobacteriae, Alphaproteobacteria, Actinomycetia и Gammaproteobacteria. Для последней временной точки: k0 и k5 – Acidobacteriae, k25 – Gammaproteobacteria.




Рис. 26: Состав на уровне рода (lv 6).

Самым частым родом в загрязненных образцах является Paraburkholderia: в контроле его почти нет, а вот в загрязненных образцах на поздних временах он превалирует.

Можно сказать, что данная картина, в целом, ожидаема при загрязнении керосином. Ведь это органика, которая резко увеличилась в количестве. Изменение родового состава связано с тем, что некоторые бактерии более устойчивы к бедным средам и неспособны расщеплять длинные углеводороды. На смену им приходят иные рода.

Филогенетическое дерево

Построил дерево через <https://itol.embl.de/>, получилось нечто следующее:




Рис. 27: Дерево для почвы.

Задача 6




Рис. 28: PCoA weighted UniFrac.

Видим, что образы в первой временной точке похожи и лежат в одной группе вне зависимости от кол-ва керосина.

Со временем образы уходят вдоль первой оси.

Для k5 наблюдается некоторое восстановление в силу сближения образов с контролем с течением времени. Для k25 такого не наблюдается.




Рис. 29: PCoA unweighted UniFrac.

Unweighted UniFrac показывает лишь отсутствие и наличие таксонов, а weighted показывает ещё их отношение в кол-ве. Получается, что основные различия между образцами в пропорции, а не в таксономическом составе.




Рис. 30: Распределения weighted UniFrac.

Анализ PERMANOVA подтверждает наши картинки. Все три пары значимы.

Задача 7

Резюмируя, видим, что обе дозы значимо отличаются от контроля, а между собой k5 и k25 не особо отличаются. День 3 сильно отличается от остальных временных точек. Основной упадок таксономического

PERMANOVA results	
method name	PERMANOVA
test statistic name	pseudo-F
sample size	36
number of groups	3
test statistic	8.100658
p-value	0.001
number of permutations	999

Рис. 31: Таблица попарных сравнений PERMANOVA




Рис. 32: Индекс Шеннона доза и время вместе.




Рис. 33: Индекс Шеннона по загрязнению.




Рис. 34: Индекс Шеннона по времени.

разнообразия происходит в первые три месяца, дальше процесс тормозится.

Выводы

Как можно заметить, почва хорошо переносит слабое загрязнение. Таксономическое разнообразие уменьшается медленно, потом даже наблюдаются наметки восстановления с течением времени.

Сильное загрязнение сильно уменьшает исходное разнообразие практически до одного семейства бактерий. Каких-либо признаков восстановления не наблюдается.