

Домашнее задание 6

Практическое использование алгоритма BLAST

Кирилл Афанасьев, гр. Б06-305

Задание 1: Идентификация белка и интерпретация E-value

Используем неизвестный белок NP_000537.3. Запустим белковый Блест (BLASTP) с параметрами по умолчанию на базе данных nr (Non-redundant protein sequences). Вывод программы представлен на Рис. 1 ниже:

The screenshot displays the NCBI BLAST search results for the query NP_000537.3. The interface includes a 'Job Title' section with details like RID (XWFSRKT014), Program (BLASTP), Database (nr), and Query ID (lclQuery_613424). A 'Filter Results' panel allows filtering by organism, percent identity, E-value, and query coverage. Below this, a 'Compare these results against the new Clustered nr database' button is visible. The main section, 'Sequences producing significant alignments', shows a table of results with columns for Description, Scientific Name, Max Score, Total Score, Query Cover, E-value, Per. Ident, Acc. Len, and Accession. The top hit is 'cellular tumor antigen p53 isoform X1 (Gorilla gorilla gorilla)' with an E-value of 0.0.

Description	Scientific Name	Max Score	Total Score	Query Cover	E-value	Per. Ident	Acc. Len	Accession
cellular tumor antigen p53 isoform X1 (Gorilla gorilla gorilla)	Gorilla gorilla gorilla	814	814	100%	0.0	99.75%	408	XP_063556659.1
Chain K, Cellular tumor antigen p53 (Homo sapiens)	Homo sapiens	814	814	100%	0.0	100.00%	395	ZXZZ_K
Chain C, Cellular tumor antigen p53 (Homo sapiens)	Homo sapiens	814	814	100%	0.0	100.00%	417	BR1F_C
cellular tumor antigen p53 isoform a (Homo sapiens)	Homo sapiens	813	813	100%	0.0	100.00%	393	NP_000537.3
mutant tumor protein p53 (Homo sapiens)	Homo sapiens	813	813	100%	0.0	99.75%	393	AYE20817.1
mutant tumor protein p53 (Homo sapiens)	Homo sapiens	812	812	100%	0.0	99.75%	393	AYE20813.1
mutant tumor protein p53 (Homo sapiens)	Homo sapiens	812	812	100%	0.0	99.75%	393	AYE20823.1
p53 antigen (Homo sapiens)	Homo sapiens	812	812	100%	0.0	99.75%	393	AAA61212.1
cellular tumor antigen p53 isoform X2 (Gorilla gorilla gorilla)	Gorilla gorilla gorilla	812	812	100%	0.0	99.75%	393	XP_004058559.3

Рис. 1: Вывод программы.

- Исходя из списка хитов, можем сказать, что top hit - cellular tumor antigen p53 isoform X1 у вида *Gorilla gorilla gorilla* (western lowland gorilla).
- Значение E-value первого хита равно 0.00.
- Данное значение равное нулю, означает, что вероятность случайного совпадения искомой последовательности с одной из базы данных nr практически равна нулю.

Raw score - это сумма баллов с совпадение аминокислот, исходя из матрицы замен, учитывающая штрафы за пропуски. Его значение сильно зависит от длины последовательности и используемой матрицы замен. E-value позволяет нормализовать сырой балл с учетом размера базы данных и статистической модели.

Задание 2: Поиск транслированных последовательностей

Используем нуклеотидную последовательность мРНК бета-глобина человека (NM_000518.5).

- Для поиска гомологичных белков используем инструмент BLASTX. Т.к. он переводит искомую нуклеотидную последовательность в 6 всевозможных рамок считывания.
- Запустим BLASTX на базе nr. Получим следующий вывод:

Job Title: NM_000518.5
RID: XWRB0ZGG014
Program: BLASTX
Database: nr
Query ID: lcl|Query_676037
Description: NM_000518.5
Molecule type: dna
Query Length: 628
Other reports: ?

Filter Results
Organism: only top 20 will appear
Type common name, binomial, taxid or group name
+ Add organism
Percent Identity: 100 to 100
E value: 1e-101 to 1e-101
Query Coverage: 100 to 100
Filter Reset

Compare these results against the new Clustered nr database BLAST

Descriptions Graphic Summary Alignments Taxonomy

Sequences producing significant alignments Download Select columns Show 100

select all 100 sequences selected

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	70%	1e-101	100.00%	148	AAX37051.1
hemoglobin beta, partial [synthetic construct]	synthetic construct	301	301	70%	1e-101	100.00%	148	AAX29557.1
hemoglobin subunit beta (Homo sapiens)	Homo sapiens	301	301	70%	2e-101	100.00%	147	NP_000509.1
hemoglobin subunit beta (Gorilla gorilla gorilla)	Gorilla gorilla gorilla	300	300	70%	6e-101	99.32%	147	XP_018891709.1
beta globin chain variant (Homo sapiens)	Homo sapiens	299	299	70%	6e-101	99.32%	147	AAN84548.1
beta-globin (Homo sapiens)	Homo sapiens	299	299	70%	6e-101	99.32%	147	ACU56984.1
beta globin (Homo sapiens)	Homo sapiens	299	299	70%	6e-101	99.32%	147	AZ39780.1
hemoglobin beta chain (Homo sapiens)	Homo sapiens	299	299	70%	8e-101	99.32%	147	AAD19696.1

Рис. 2: Вывод программы.

Видим, что на лучшим найденным белком является синтетический конструктор бета-глобина. Однако, он имеет одинаковый скор с бета-субъединицей гемоглобина человека, что соотносится с исходной мРНК.

- Рассмотрим детали выравнивания наилучшего белка:

Download GenPept Graphics

hemoglobin beta, partial [synthetic construct]
Sequence ID: AAX37051.1 Length: 148 Number of Matches: 1

Range 1: 1 to 147 GenPept Graphics

Score	Expect	Method	Identities	Positives	Gaps	Frame
301 bits(771)	1e-101	Compositional matrix adjust.	147/147(100%)	147/147(100%)	0/147(0%)	+3
Query 51	MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPK					230
Sbjct 1	MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAMGNPK					60
Query 231	VKAHGKKVLGAFSDGLAHLDNLKGTFATLSEHCDKLVDPENFRLLGNVLVCVLAHHFG					410
Sbjct 61	VKAHGKKVLGAFSDGLAHLDNLKGTFATLSEHCDKLVDPENFRLLGNVLVCVLAHHFG					120
Query 411	KEFTTPVQAAVKVAVGANALAHKYH					491
Sbjct 121	KEFTTPVQAAVKVAVGANALAHKYH					147

Рис. 3: Детали выравнивания.

Полученная рамка считывания (Frame): +3

Аналогичная рамка характерна и для субъединицы бета человека (hemoglobin subunit beta [Homo sapiens]).

- Этот подход надежнее, т.к. в мРНК м.б. несколько рамок считывания. BlastX проверяет их все, а при самостоятельной трансляции не всегда есть возможность выбрать верную, особенно на больших длинах последовательности.

Задание 3: Влияние матриц аминокислотных замен

В качестве объекта рассмотрим миоглобин человека: NP_005359.1.

- Запустим BLASTp для этой последовательности по базе данных SwissProt, используя стандартные параметры (матрица BLOSUM62). Найдем гомолог миоглобина из организма *Danio rerio*. Полученный alignment:

Download	GenPept	Graphics	Next	Previous	Descriptions
RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio] Sequence ID: Q6VN46.3 Length: 147 Number of Matches: 1					
Range 1: 5 to 147 GenPept Graphics			Next Match	Previous Match	Related Information
Score	Expect	Method	Identities	Positives	Gaps
115 bits(289)	9e-35	Compositional matrix adjust.	63/146(43%)	88/146(60%)	3/146(2%)
Query 9	QVLNMGKVEADIPGHGQEV	LRLFKGHPETLEKFDKFKHLKSEDEMKASEDLKKHGAT	68		
	LVL MG VEAD	+G EVL RLFK +P+TL+ F KF + S+ ++ S + HGAT			
Sbjct 5	DLVLKCGAVEADYAANGGEVLNRLFK	KEYPDTLKLFPKFSGI-SQGDLAGSPAUAHGAT	63		
Query 69	VLTAIGGILKKKGHEAEIKPLAQSHATKHKIPVKYLEFISECIIVQLQSKHPGDFGADA	128			
	VL LG +LK KG H A +KPLA +HA HK+ +	I+E +++V+ K D A			
Sbjct 64	VLKKGELGELKAKGDAALLKPLANTHANIHKVALNNFRLITEVLVKVMAEKAGLD--AAG	121			
Query 129	QGANMKALELFRKDMASNYKELGFQG	154			
	QGA+ + ++ D+ YKE+GF G				
Sbjct 122	QGALRRVMDAVIDGIDGYKEIGFAG	147			

Значение E-value: $9 \cdot 10^{-35}$.

Bit Score: 115.

Процент идентичности (Identity): 43.15 %.

- Теперь в параметрах алгоритма изменим матрицу на PAM30. Получим следующие результаты:

Download	GenPept	Graphics	Next	Previous	Descriptions
RecName: Full=Myoglobin; AltName: Full=Nitrite reductase MB; AltName: Full=Pseudoperoxidase MB [Danio rerio] Sequence ID: Q6VN46.3 Length: 147 Number of Matches: 1					
Range 1: 2 to 147 GenPept Graphics			Next Match	Previous Match	Related Information
Score	Expect	Method	Identities	Positives	Gaps
119 bits(274)	2e-29	Compositional matrix adjust.	62/149(42%)	73/149(48%)	3/149(2%)
Query 6	GENQLVLNMGKVEADIPGHGQEV	LRLFKGHPETLEKFDKFKHLKSEDEMKASEDLKKH	65		
	+ LVL MG VEAD	G EVL RLFK P+TL F KF S+ ++ S H			
Sbjct 2	ADHDLVLKCGAVEADYAANGGEVLNRLFK	KEYPDTLKLFPKFSGI-SQGDLAGSPAUAH	60		
Query 66	GATVLTALGGILKKKGHEAEIKPLAQSHATKHKIPVKYLEFISECIIVQLQSKHPGDFG	125			
	GATVL LG LK KG H A KPLA HA HK+ +	I E + V+ K			
Sbjct 61	GATVLKKGELGELKAKGDAALLKPLANTHANIHKVALNNFRLITEVLVKVMAEK--AGLD	118			
Query 126	ADAQGANMKALELFRKDMASNYKELGFQG	154			
	A QGA+ + ++ D YKE GF G				
Sbjct 119	AAGQALRRVMDAVIDGIDGYKEIGFAG	147			

Значение E-value: $2 \cdot 10^{-29}$.

Bit Score: 119.

Процент идентичности (Identity): 41.61 %.

Длина покрытия (Query cover): 97 %.

- Матрица PAM30 используется для поиска белков с высоким процентом идентичности, т.е. эволюционно близких. Миоглобины человека и *Danio rerio* достаточно далеки (процент идентичности 43.15 %). Поэтому штрафы за несовпадение в PAM30 сильно больше, чем в BLOSUM62. Из-за этого истинное выравнивание получает более низкий raw score, а значит больший E-value, что мы и наблюдаем. Таким образом, PAM30 - больше подходит для поиска близких гомологов, а BLOSUM62 - далеких.

Задание 4: Таксономические фильтры и поиск ортологов

В данной задаче используем белок продукт гена *BRCA1*: NP_009225.1.

1. Запустим BLASTp для этой последовательности по базе данных SwissProt. В поле *Organism* введем название вида плодовой мушки: *Drosophila melanogaster* (taxid:7227). Получим следующее:

Job Title: NP_009225.1 breast cancer type 1 susceptibility
RID: XWV2SP3X016
Program: BLASTP
Database: swissprot
Query ID: lcl|Query_11340953
Description: NP_009225.1 breast cancer type 1 susceptibility protein is ...
Molecule type: amino acid
Query Length: 1863

Filter Results
Organism: only top 20 will appear
Percent Identity: [] to []
E value: [] to []
Query Coverage: [] to []
Filter Reset

Sequences producing significant alignments
Download Select columns Show 100

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
RecName: Full=E3 ubiquitin-protein ligase RING1; AltName: Full=RING-type E3 ubiquitin transferase RING1; AltName: ...	Drosophila melan...	49.8	49.8	3%	3e-06	39.06%	435	Q0VB08


2. Лучший хит мушки: E3 ubiquitin transferase RING1 - некоторая убиквитин трансфераза.

3. Query cover: 3 %.

Identity: 39.06 %.

Исходя из процента идентичности можно сделать вывод, что не очень похож.

4. Посмотрим на графическое представление выравнивания:



Видим, что консервативны только определенные домены белка. Конкретно, сохраняются RING-домены и BRCT-домены. Это говорит о том, что в ходе эволюции *BRCA1* данные домены играли основную функцию, в то время как остальные сильно изменялись от таксона к таксону.